

WYDAJNOŚĆ ZŁĄCZEŃ I ZAGNIEŹDZEŃ DLA SCHEMATÓW ZNORMALIZOWANYCH I ZDENORMALIZOWANYCH

Karol Pastuszka

04.06.2021

1) Cel ćwiczenia oraz jego wykonanie.

Utworzyłem bazę danych zawierającą informacje na temat tabeli stratygraficznej oraz jednostek z których się ona składa. Wykonałem to w celu sprawdzenia wydajności dla zapytań oraz zagnieźdzeń dla tabeli znormalizowanych i nieznormalizowanych oraz zbadania wpływu indeksowania jako mechanizmu do optymalizacji baz danych SQL. Utworzyłem tabelę zawierającą dane geochronologiczną w postaci znormalizowanej oraz zdenormalizowanej oraz tabelę Milion która została wypełniona liczbami od 0 do 999 999. Zapytania łączyły zawsze jedną z tabel geochronologicznych z tabelą Milion.

Zapytanie 1 (1 ZL), którego celem jest złączenie syntetycznej tablicy miliona wyników z tabelą geochronologiczną w postaci zdenormalizowanej, przy czym do warunku złączenia dodano operację modulo, dopasowującą zakresy wartości złączanych kolumn.

```
SELECT COUNT(*) FROM Milion INNER JOIN GeoTabela ON (mod(Milion.liczba,88)=(GeoTabela.id_pietro));
```

Zapytanie 2 (2 ZL), którego celem jest złączenie syntetycznej tablicy miliona wyników z tabelą geochronologiczną w postaci znormalizowanej, reprezentowaną przez złączenia pięciu tabel.

```
SELECT COUNT(*) FROM Milion  
INNER JOIN GeoPietro ON (mod(Milion.liczba,88)=GeoPietro.id_pietro)  
NATURAL JOIN GeoEpoka NATURAL JOIN GeoOkres NATURAL JOIN GeoEra NATURAL JOIN GeoEon;
```

Zapytanie 3 (3 ZG), którego celem jest złączenie syntetycznej tablicy miliona wyników z tabelą geochronologiczną w postaci zdenormalizowanej, przy czym złączenie jest wykonywane poprzez zagnieźdzenie skorelowane.

```
SELECT COUNT(*) FROM Milion WHERE mod(Milion.liczba,88)  
= (SELECT id_pietro FROM GeoTabela WHERE mod(Milion.liczba,88)=(id_pietro));
```

Zapytanie 4 (4 ZG), którego celem jest złączenie syntetycznej tablicy miliona wyników z tabelą geochronologiczną w postaci znormalizowanej, przy czym złączenie jest wykonywane poprzez zagnieżdżenie skorelowane, a zapytanie wewnętrzne jest złączeniem tabel poszczególnych jednostek.

```
SELECT COUNT(*) FROM Milion
WHERE mod(Milion.liczba,88) in (SELECT GeoPietro.id_pietro FROM GeoPietro
NATURAL JOIN GeoEpoka NATURAL JOIN GeoOkres NATURAL JOIN GeoEra NATURAL JOIN GeoEon);
```

Następnie przeprowadziłem testy wydajności, na darmowym oprogramowaniu **MySQL oraz SQLServer**.

W pierwszej kolejności wykonałem pomiary szybkości wykonania zapytań, które nie miały nałożonych indeksów na kolumny, następnie powtórzyłem to dla zapytań z indeksami nałożonymi na kolumny. Wykonałem 15 powtórzeń dla każdego zapytania w obu wariantach.

2) Konfiguracja sprzętowa komputerów, na którym zostały wykonane testy.


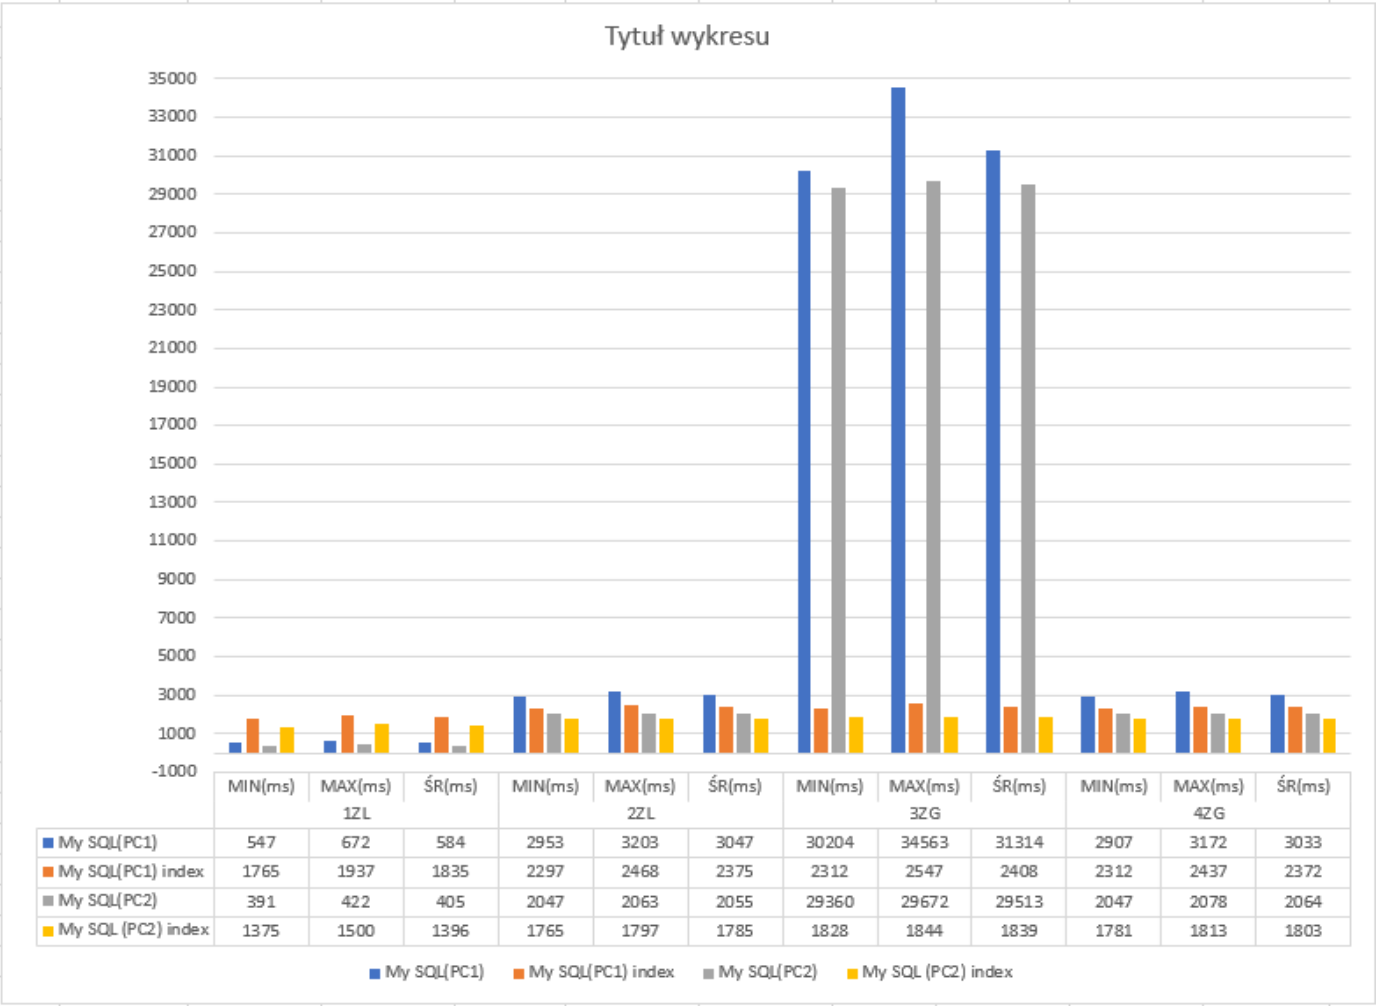
Komputer nr1.

- CPU: Intel(R) Core(TM) i7-7700 CPU @ 3.6GHz 4.1Ghz,
- RAM: Pamięć DDR4 2 x 8.00GB (2133/3200 MHZ)
- SSD Kingston SA2000M8500G, 500GB,
- S.O: Windows 10 Pro x86,
- MySQL, wersja Community Server 8.0.24,
- SQL Server 15.0.2000.5

Komputer nr2.

- CPU: Intel(R) Core(TM) i9-10900K CPU @ 3.7GHz 5.1Ghz,
- RAM: Pamięć DDR4 2 x 16.00GB (3600 MHZ)
- SSD Dysk SSD Samsung 970 EVO Plus 1 TB M.2 2280 PCI-E x4 Gen3 NVMe
- S.O: Windows 10 Pro x86,
- MySQL, wersja Community Server 8.0.24,

3) Wyniki



4) Wnioski

Analizując otrzymane wyniki możemy dojść do wniosku, że nałożenie indeksów przyczynia się do zwiększenia prędkości oraz zmniejszenia czasu wykonywania się kwerend.

- Zagnieżdżenia skorelowane są wolniejsze w wykonaniu niż złączenia w przypadku używania MySQL
- Jedynym wypadkiem, w którym postać zdenormalizowana jest wolniejsza jest zapytanie 1 dla MySQL, średni czas wykonania po indeksowaniu znacznie wzrósł. (ok 330%).
- Dla zapytania 3 (MySQL) występuje olbrzymi spadek o ok 1450 %.
- W SQL Serwerze zmiany te nie są aż tak drastyczne i widoczny jest spadek średniego czasu wraz z wprowadzeniem indeksowania.
- SQL Serwer poradził sobie zdecydowanie lepiej z tym zadaniem niż MySQL.

Analiza została wykonana w MySQL dla dwóch różnych komputerów w celu potwierdzenia swoich spostrzeżeń oraz sprawdzenia poprawności wyliczeń. Natomiast w SQL Server tylko dla jednego, gdyż wyniki były do siebie zbliżone.